

Predlog – Hotel Booking Dataset

Kao predlog za seminarski rad izabrale smo skup podataka Hotel Booking sa Kaggle platforme.

<https://www.kaggle.com/datasets/mojtaba142/hotel-booking>

Skup podataka *Hotel Booking* sadrži informacije o rezervacijama u gradskim i resort hotelima u periodu od 1. jula 2015. do 31. avgusta 2017. godine. Obuhvata različite attribute koji opisuju rezervacije, goste, smeštaj, način rezervisanja i prethodnu istoriju rezervacija. Pored osnovnih podataka, dataset uključuje i informacije o otkazivanju rezervacije (*is_canceled*), što ga čini pogodnim za prediktivne modele. Takođe, prisutne su nedostajuće vrednosti i outlier-i, što omogućava detaljnu analizu i obradu podataka pre modelovanja.


Skup podataka sadrži **119.390 redova** i **36 kolona**, gde svaki red predstavlja jednu rezervaciju, dok kolone predstavljaju različite karakteristike te rezervacije.

Skup podataka sadrži **nedostajuće vrednosti** u kolonama:


- children (4)
- country (488)
- agent (16.340)
- company (112.593)

Za ciljnu promenljivu odabrana je kolona **is_canceled**, koja označava da li je rezervacija otkazana. Vrednost 0 označava da rezervacija nije otkazana, dok vrednost 1 označava da jeste. Zadatak predstavlja binarni klasifikacioni problem.


Na grafiku je prikazana raspodela target promenljive *is_canceled*, iz koje se može videti da je veći broj rezervacija realizovan, dok je manji broj otkazan.




Pored target promenljive, analizirale smo i njen odnos sa kolonama **lead_time**, **adr** i **deposit_type**, kako bismo uočile na koji način ove promenljive utiču na otkazivanje rezervacija.



Na grafiku je prikazan odnos između promenljive **lead_time** i target promenljive **is_canceled**. Može se primetiti da se najveći broj rezervacija pravi sa manjim brojem dana unapred, dok rezervacije sa većim lead_time češće imaju veću verovatnoću otkazivanja.




Na grafiku je prikazan odnos između promenljivih **deposit_type** i **is_canceled**. Može se primetiti da najveći broj rezervacija pripada kategoriji „No Deposit“, dok kod rezervacija sa tipom „Non Refund“ postoji znatno veći broj otkazivanja.



Na grafiku je prikazan odnos između promenljive **total_of_special_requests** i target promenljive **is_canceled**. Može se primetiti da gosti sa većim brojem specijalnih zahteva ređe otkazuju rezervacije.

Analizirajući odnos između promenljive **adr** i target promenljive **is_canceled**, teže je uočiti jasnu povezanost zbog velikog broja **outlier**-a. Pored nedostajućih vrednosti, u datasetu su prisutne i ekstremne vrednosti, posebno u koloni **adr**, što može biti značajno u daljoj analizi podataka. Primenom boxplot metode detektovano je 3793 outlier-a u koloni **adr**.

```
> length(boxplot.stats(df.hotel_booking$adr)$out)
[1] 3793
```



U okviru feature engineering procesa planirano je kreiranje novih atributa kako bi se iz postojećih podataka izvukle dodatne korisne informacije. Na taj način podaci mogu biti bolje prilagođeni za analizu i izgradnju modela, što može doprineti preciznijim rezultatima.

Neki od novih atributa koje planiramo da kreiramo su:

- **total_guests** - predstavlja ukupan broj gostiju u jednoj rezervaciji, dobijen sabiranjem broja odraslih, dece i beba.
- **total_nights** - predstavlja ukupan broj noćenja, dobijen sabiranjem boravka tokom radnih dana i vikenda. Ovaj atribut opisuje ukupnu dužinu boravka gostiju.
- **price_per_guest** - predstavlja cenu noćenja po gostu, dobijenu deljenjem prosečne dnevne cene (adr) sa ukupnim brojem gostiju.

Milena Đukić 40/2020

Angelina Lazarević 66/2022